

F Coaching IA Commercial

- Date: 2026-06-16
- Status: Draft implementation handoff
- Scope: conception technique, pipeline, architecture, scoring, plan de vente
- Boundary: pas encore de code, pas de migration, pas de deploiement

Objectif Produit

Ajouter un systeme de coaching IA qui analyse un audio de prospection correspondant a une porte, transcrit l'audio avec Whisper, evalue la conversation avec un LLM selon un plan de vente configurable, puis produit un resultat structure exploitable par les admins/directeurs.

Principe fondamental valide:

```
1 audio fourni = 1 porte = 1 analyse coaching = 1 score potentiel
```

Le LLM peut identifier des moments internes dans la conversation, mais il ne doit pas redécouper l'audio en plusieurs portes.

Resultats Des Tests IA

Cette fiche ne sort pas de nulle part. Elle est le resultat de plusieurs tests concrets realises avant de parler d'architecture produit.

Chemin Parcouru

1. Idee initiale: ajouter une partie "Analyse Coach IA" qui prend une transcription, la compare a un plan de vente et retourne un output structure avec score et remarques.
2. Premiere clarification: on a decide de ne pas commencer par l'architecture, mais par un test des outils eux-memes: Whisper + LLM.
3. Correction importante: le pipeline Pro-Win existant n'est pas une contrainte. Il peut etre garde, simplifie ou remplace selon les resultats du test.
4. Test LLM: l'URL initiale sans port ne repondait pas; on a trouve le bon endpoint OpenAI-compatible sur `:11434/v1`.

5. Test Whisper: le service local `localhost:9000` ne tournait pas; on a utilise Whisper staging via tunnel SSH vers le conteneur `pro-win-staging-whisper`.
6. Tests audio: on a transcrit plusieurs MP4 reels et envoie les transcriptions au LLM.
7. Correction produit majeure: l'utilisateur a precise que le decoupage donne correspond deja a une porte. Donc `1 audio = 1 porte = 1 score`, pas plusieurs scores de portes.
8. Correction scoring majeure: le score n'est pas statique. Le plan de vente porte les etapes, criteres, points et regles. Le LLM juge les criteres, le backend calcule.

LLM

- Endpoint fonctionnel: `https://finanssor-data-center-v1.tail446cc0.ts.net:11434/v1`
- API: OpenAI-compatible `/chat/completions`
- Modele teste: `gemma4-26b`
- Auth: Bearer token
- Observation: le LLM donne des analyses utiles, mais il faut valider strictement le JSON.

Whisper

- Whisper staging teste via tunnel SSH vers le conteneur `pro-win-staging-whisper`.
- Endpoint teste: `/transcribe/prospection?language=auto`
- Le service transcrit correctement les audios MP4.
- Sur les extraits courts/bruités, la qualite peut etre insuffisante pour un score officiel.
- Sur un extrait plus long de 11 min 24, la transcription etait exploitable pour du coaching.

Enseignements

- Le scoring doit venir du plan de vente, pas d'une grille codee en dur.
- Le backend doit calculer le score final, pas le LLM seul.
- Le LLM doit juger des criteres et citer les preuves.
- Il faut des statuts qualite: `ANALYZED`, `LOW_CONFIDENCE`, `INEXPLOITABLE`, `FAILED`.
- Il faut separer:
 - qualite transcription;
 - completude de l'interaction;
 - respect du plan de vente;
 - confiance globale;
 - score officiel.

Tests Audio Realises

Audio	Portion	Whisper	LLM
<code>3_Rue_de_la_Montee_95520_Osny__3_2026-05-28T15-39-02.532Z.mp4</code>	complet, 43.68s	Transcription exploitable mais bruitée, 2 segments	Score raisonnable autour de 25/100
<code>2_Rue_de_la_Montee_95520_Osny__2_2026-05-28T15-58-43.852Z.mp4</code>	complet, 19.76s	Transcription tres faible, 1 segment	Score 5/10 marque inexploitable
<code>14_Rue_Saint_Exup_ry__91350_Grigny__France_2026-06-03T18-12-20.223Z (1).mp4</code>	30:00 a 41:24, 684s	Transcription riche, 29 segments, 6438 caracteres	Score glob 65/100, qualite transcriptic 75/100


Artifacts principaux:

- `designs/test-artifacts/2026-06-16-osny-test-report.md`
- `designs/test-artifacts/2026-06-16-osny-2-test-report.md`
- `designs/test-artifacts/2026-06-16-grigny-30m-41m24s-test-report.md`


Decisions Issues Des Tests

Decision	Pourquoi
Utiliser Whisper comme outil de transcription, pas forcement le pipeline actuel tel quel	Le tunnel et les tests ont prouve l'outil; l'integration produit peut etre adaptee ensuite
Appeler le LLM cote backend uniquement	Secrets, donnees personnelles et validation JSON ne doivent pas aller dans le navigateur
Ne pas faire confiance au score brut LLM	Les tests ont donne des variations de score selon prompt et format
Valider/reparer le JSON LLM	Une reponse est revenue avec fence Markdown, une autre avec <code>stepScores</code> en objet
Scorer par porte	L'utilisateur a precise que l'extrait donne correspond a une porte
Piloter le scoring par le plan de vente	Le poids des etapes et criteres depend du plan, pas d'une grille statique
Ajouter <code>LOW_CONFIDENCE</code> et <code>INEXPLOITABLE</code>	Les extraits courts/bruites ne doivent pas produire un score officiel trompeur

Architecture Cible



Pipeline General



Acces Aux Services IA

Configuration LLM

Variables d'environnement backend:

```

AI_COACH_LLM_BASE_URL=https://finanssor-data-center-v1.tail446cc0.ts.net:11434/v1
AI_COACH_LLM_API_KEY=<secret>
AI_COACH_LLM_MODEL=gemma4-26b
AI_COACH_LLM_TIMEOUT_MS=120000
  
```

Appel:

```
POST ${AI_COACH_LLM_BASE_URL}/chat/completions
Authorization: Bearer ${AI_COACH_LLM_API_KEY}
Content-Type: application/json
```

Payload minimal:

```
{
  "model": "gemma4-26b",
  "response_format": { "type": "json_object" },
  "temperature": 0,
  "messages": [
    { "role": "system", "content": "Tu es un coach commercial..." },
    { "role": "user", "content": "Transcript + plan + schema..." }
  ]
}
```

Contraintes:

- Ne jamais hardcoder l'API key.
- Forcer `temperature: 0` pour stabiliser le scoring.
- Utiliser `response_format`, mais ne pas lui faire confiance aveuglement.
- Toujours valider la forme JSON apres reponse.

Configuration Whisper

Deux modes possibles:

Mode A - Reutiliser Whisper via backend/staging existant

Le backend actuel utilise:

```
WHISPER_API_URL=http://localhost:9000
```

et appelle:

```
POST ${WHISPER_API_URL}/transcribe/prospection?language=auto
multipart/form-data file=<audio.mp4>
```

Mode B - Service Whisper configurable pour Coaching IA

Variables recommandees:

```
AI_COACH_WHISPER_BASE_URL=<url whisper>
AI_COACH_WHISPER_ENDPOINT=/transcribe/prospection
AI_COACH_WHISPER_LANGUAGE=auto
AI_COACH_WHISPER_TIMEOUT_MS=1200000
```

Recommandation:

- En staging/prod, le backend doit appeler Whisper par le reseau interne Docker/VPS, pas par tunnel SSH.
- Le tunnel SSH est seulement un outil de test local.

Gestion Du Plan De Vente

Le plan de vente est le coeur du scoring. Il doit etre configurable et versionne.

Principe

```
Plan de vente = etapes + criteres + points + regles
LLM = juge les criteres avec preuves
Backend = calcule le score final
```

Le score n'est pas statique. Chaque plan definit ses propres poids, criteres et seuils.

Format Cible Du Plan

```
{
  "id": "energy-door-to-door-v1",
  "name": "Plan de vente Energie Porte-a-Porte",
  "version": 1,
  "status": "ACTIVE",
  "scoringScale": 100,
  "minimums": {
    "minTranscriptQualityScore": 50,
    "minCommercialCompletenessScore": 40,
    "minEvidenceForOfficialScore": true
  },
  "steps": [
    {
      "key": "accroche",
      "label": "Accroche",
      "objective": "Creer un contact poli et obtenir quelques secondes d'attention.",
      "weight": 10,
      "criteria": [
        {
          "key": "salutation",
          "label": "Salutation polie",
          "points": 4,
          "evidenceRequired": true,
          "expectedSignals": ["bonjour", "madame", "monsieur"],
          "badSignals": ["pas de salutation", "ton brusque"]
        },
        {
          "key": "disponibilite",
          "label": "Verification de disponibilite",
          "points": 3,
          "evidenceRequired": true,
          "expectedSignals": ["je ne vous derange pas", "ca prend deux minutes"]
        },
        {
          "key": "fluidite",
          "label": "Accroche claire et fluide",
          "points": 3,
          "evidenceRequired": false,
          "badSignals": ["en fait repete", "en gros repete", "message confus"]
        }
      ]
    },
    {
      "key": "qualification",
      "label": "Qualification",
      "objective": "Comprendre la situation energie du foyer.",
    }
  ]
}
```

```
"weight": 20,
"criteria": [
  {
    "key": "titulaire",
    "label": "Identifie ou verifie le titulaire",
    "points": 5,
    "evidenceRequired": true
  },
  {
    "key": "compteur_conso",
    "label": "Questionne compteur ou consommation",
    "points": 5,
    "evidenceRequired": true
  },
  {
    "key": "energie",
    "label": "Identifie electricite/gaz/chauffage",
    "points": 5,
    "evidenceRequired": true
  },
  {
    "key": "coordonnees",
    "label": "Collecte les informations utiles si necessaire",
    "points": 5,
    "evidenceRequired": true
  }
]
}
```

Edition Du Plan

V1:

- stocker le plan JSON en base;
- interface admin simple pour consulter/modifier;
- un seul plan actif global;
- toute analyse garde `salesPlanId` et `salesPlanVersion`.

V2:

- plans multiples par offre/campagne/equipe;
- duplication d'un plan;
- brouillon puis publication;
- comparaison entre versions.

Calcul Du Score

Etape 1 - Pre-checks

Avant LLM ou avant score officiel:

```
durationSec < seuil_minimum -> INEXPLOITABLE
transcript trop court -> INEXPLOITABLE
transcriptQualityScore < seuil plan -> LOW_CONFIDENCE
pas de contenu commercial clair -> COACHING_LIMITED
```

Etape 2 - Evaluation LLM Des Criteres

Le LLM recoit:

- transcript;
- metadata audio;
- plan actif structure;
- schema de sortie strict;
- consigne: chaque critere valide doit citer une preuve.

Le LLM renvoie:

```
{
  "criteriaResults": [
    {
      "stepKey": "accroche",
      "criterionKey": "salutation",
      "status": "passed",
      "pointsSuggested": 4,
      "evidence": ["Bonjour Madame"],
      "comment": "Salutation presente."
    },
    {
      "stepKey": "accroche",
      "criterionKey": "disponibilite",
      "status": "missing",
      "pointsSuggested": 0,
      "evidence": [],
      "comment": "Aucune verification claire de disponibilite."
    }
  ],
  "doorMoments": [
    {
      "type": "objection",
      "approxStartSec": 120,
      "approxEndSec": 165,
      "summary": "La cliente indique que ses prix actuels semblent corrects."
    }
  ],
  "strengths": ["Bonne qualification"],
  "improvements": ["Closing absent"],
  "recommendedActions": ["Proposer une prochaine action concrete"],
  "riskFlags": ["TRANSCRIPT_NOISY"]
}
```

Etape 3 - Calcul Backend

Le backend ne fait pas confiance aux points du LLM sans controle.

Pseudo-regles:

```
Pour chaque critere du plan:
  si status = passed et evidenceRequired = true et evidence vide:
    points = 0
  sinon:
    points = clamp(pointsSuggested, 0, criterion.points)

stepRawScore = points_obtenus / points_possibles
stepWeightedScore = stepRawScore * step.weight

salesScore = somme(stepWeightedScore) / somme(weights) * 100
officialScore = salesScore ajuste par qualite/completude selon le statut
```

Exemple:

```
{
  "status": "ANALYZED",
  "salesScore": 72,
  "transcriptionQualityScore": 80,
  "commercialCompletenessScore": 65,
  "confidence": 74,
  "officialScore": 70
}
```

Statuts Recommandes

```
PENDING
TRANSCRIBING
TRANSCRIBED
ANALYZING
ANALYZED
LOW_CONFIDENCE
INEXPLOITABLE
FAILED
```


Mutations

```
createSalesPlanVersion(input: SalesPlanVersionInput!): SalesPlanVersionDto!  
publishSalesPlanVersion(id: Int!): SalesPlanVersionDto!  
runAiCoachingAnalysis(input: RunAiCoachingAnalysisInput!): AiCoachingAnalysisDto!  
retryAiCoachingAnalysis(id: Int!): AiCoachingAnalysisDto!  
markAiCoachingAnalysisReviewed(id: Int!, input: ReviewInput!):  
AiCoachingAnalysisDto!
```

Input V1

```
input RunAiCoachingAnalysisInput {  
  recordingSegmentId: Int  
  s3Key: String  
  forceRetranscribe: Boolean  
  salesPlanVersionId: Int  
}
```

V1 peut commencer avec `recordingSegmentId` si la transcription existe déjà. Pour une page de test, `s3Key` ou upload direct peut être ajouté.

Frontend Cible

Sidebar admin/directeur:

```
Coaching IA  
- Tests IA  
- Analyses  
- Plan de vente  
- Statistiques
```

Page Tests IA

Objectif: tester rapidement audio → Whisper → LLM → score.

Elements:

- upload ou sélection d'un segment/enregistrement;
- choix du plan actif;
- bouton lancer analyse;
- progression: transcription, analyse, validation;
- résultat JSON rendu lisible;

- badge statut: ANALYZED , LOW_CONFIDENCE , INEXPLOITABLE , FAILED .

Page Analyses

Objectif: exploiter les resultats.

Filtres:

- date;
- commercial;
- immeuble/porte;
- statut;
- score;
- plan/version;
- risk flags.

Colonnes:

- commercial;
- porte/immeuble;
- score officiel;
- transcription quality;
- completeness;
- statut;
- date;
- actions.

Page Plan De Vente

Objectif: gerer le plan qui pilote le scoring.

V1:

- afficher plan actif;
- editer JSON/structure;
- previsualiser poids total;
- valider criteres;
- publier une version.

Validation plan:

- somme des weights > 0;
- chaque step a une key unique;
- chaque critere a une key unique dans son step;
- points > 0;
- aucun critere obligatoire sans label.

Prompting Recommande

System:

```
Tu es un coach commercial senior en porte-a-porte energie.  
Tu evalues uniquement selon le plan fourni.  
Tu dois citer des preuves exactes de la transcription.  
Tu ne dois pas inventer.  
Tu reponds uniquement en JSON valide.
```

User:

```
Voici le plan de vente structure:  
<sales_plan_json>  
  
Voici la transcription Whisper:  
<transcript>  
  
Voici les metadonnees:  
<metadata>  
  
Pour chaque critere du plan:  
- status: passed | partial | missing | not_applicable  
- pointsSuggested entre 0 et maxPoints  
- evidence: citations exactes si evidenceRequired  
- comment  
  
Retourne le schema JSON strict suivant:  
<schema>
```

Validation JSON

Obligatoire cote backend:

- parser JSON;

- retirer fence Markdown si necessaire;
- valider avec schema;
- normaliser les champs numeriques;
- rejeter ou reparer `stepScores` objet vs array;
- verifier que les `criterionKey` existent dans le plan;
- clamp des points entre 0 et `criterion.points`;
- verifier preuves requises.

Si la validation echoue:

```
status = FAILED
error = "INVALID_LLM_OUTPUT"
llmRawOutput conserve pour debug
```

Securite Et Secrets

- LLM API key uniquement en variables d'environnement.
- Ne jamais l'ecrire dans les dossiers `designs/`, logs frontend ou payload client.
- L'appel LLM doit partir du backend, jamais du navigateur.
- Les transcriptions peuvent contenir des donnees personnelles: stockage et affichage limites aux roles autorises.
- V1 permissions: admin/directeur uniquement, comme demande.

Deploiement / VPS

Le projet deploye sur VPS. Ne pas imaginer un workflow serverless.

Avant integration prod:

- verifier connectivite backend VPS → vLLM Tailscale;
- verifier connectivite backend VPS → Whisper;
- configurer env staging d'abord;
- tester sur staging avec 2-3 audios;
- seulement apres, configurer prod.

Variables a prevoir:

```
AI_COACH_LLM_BASE_URL=  
AI_COACH_LLM_API_KEY=  
AI_COACH_LLM_MODEL=  
AI_COACH_LLM_TIMEOUT_MS=  
AI_COACH_WHISPER_BASE_URL=  
AI_COACH_WHISPER_TIMEOUT_MS=  
AI_COACH_ENABLED=
```

Phasage Recommande

Phase 1 - Prototype Technique

- service backend minimal `AiCoachingService` ;
- appel Whisper depuis un audio/segment;
- appel LLM;
- validation JSON;
- calcul score depuis plan JSON en dur ou seed local;
- endpoint GraphQL admin/directeur.

Phase 2 - Persistance

- modeles Prisma plan/version/analyse/criterion results;
- migrations;
- stockage analyse;
- retry;
- statuts.

Phase 3 - UI Tests IA

- page admin/directeur;
- lancer analyse;
- afficher transcript, score, criteres, preuves;
- montrer erreurs et low confidence.

Phase 4 - Gestion Du Plan

- page plan de vente;
- edition/versioning;

- publication plan actif.

Phase 5 - Analyses Et Stats

- liste analyses;
- filtres;
- details;
- moyennes par commercial;
- criteres faibles recurrents.

Criteres D'Acceptation V1

- ☐ Un admin/directeur peut lancer une analyse IA sur un audio/segment de porte.
- ☐ Whisper produit une transcription stockee.
- ☐ Le LLM evalue selon le plan actif.
- ☐ Le backend valide la sortie LLM.
- ☐ Le backend calcule le score final depuis le plan.
- ☐ Chaque critere score a des preuves ou une justification.
- ☐ Les audios trop courts/bruites sortent en `LOW_CONFIDENCE` ou `INEXPLOITABLE`.
- ☐ L'analyse garde le plan/version/model/date.
- ☐ Le frontend affiche score, etapes, criteres, preuves, recommandations.
- ☐ L'API key LLM n'apparait jamais cote frontend.

Decisions Encore Ouvertes

- Format exact du vrai plan de vente initial.
- Seuils de qualite officiels.
- Durée minimale d'un audio porte exploitable.
- Mode d'entree V1: `RecordingSegment` existant, upload test, ou les deux.
- Review humaine: est-ce que l'admin peut corriger/valider un score ?
- Score officiel immediat ou score brouillon jusqu'a validation ?